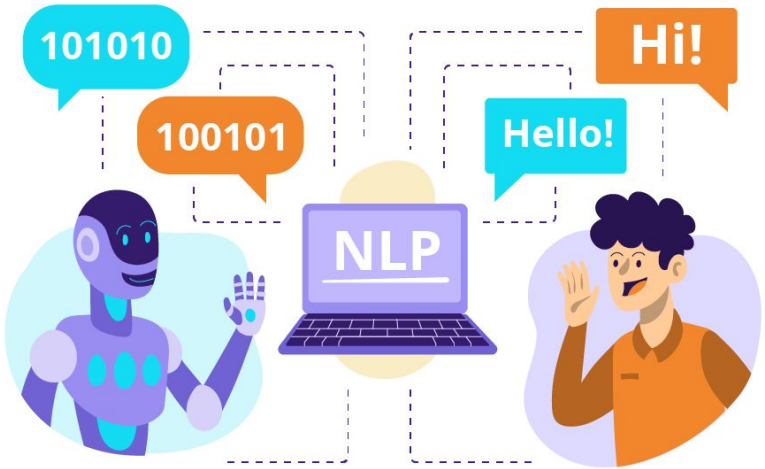
EPI Educational Group

Analyse des Avis Amazon

Traitement du Langage Naturel · E-Commerce · Expérience Client



Réalisé par: Salma Mlika — SG02 · Mai 2026

***Encadrant** : Dr. Boutheina BEN ISMAIL*

PLAN

01 Introduction & Problématique

02 Analyse Exploratoire (EDA)

03 Ingénierie du Texte

04 Modélisation Avancée

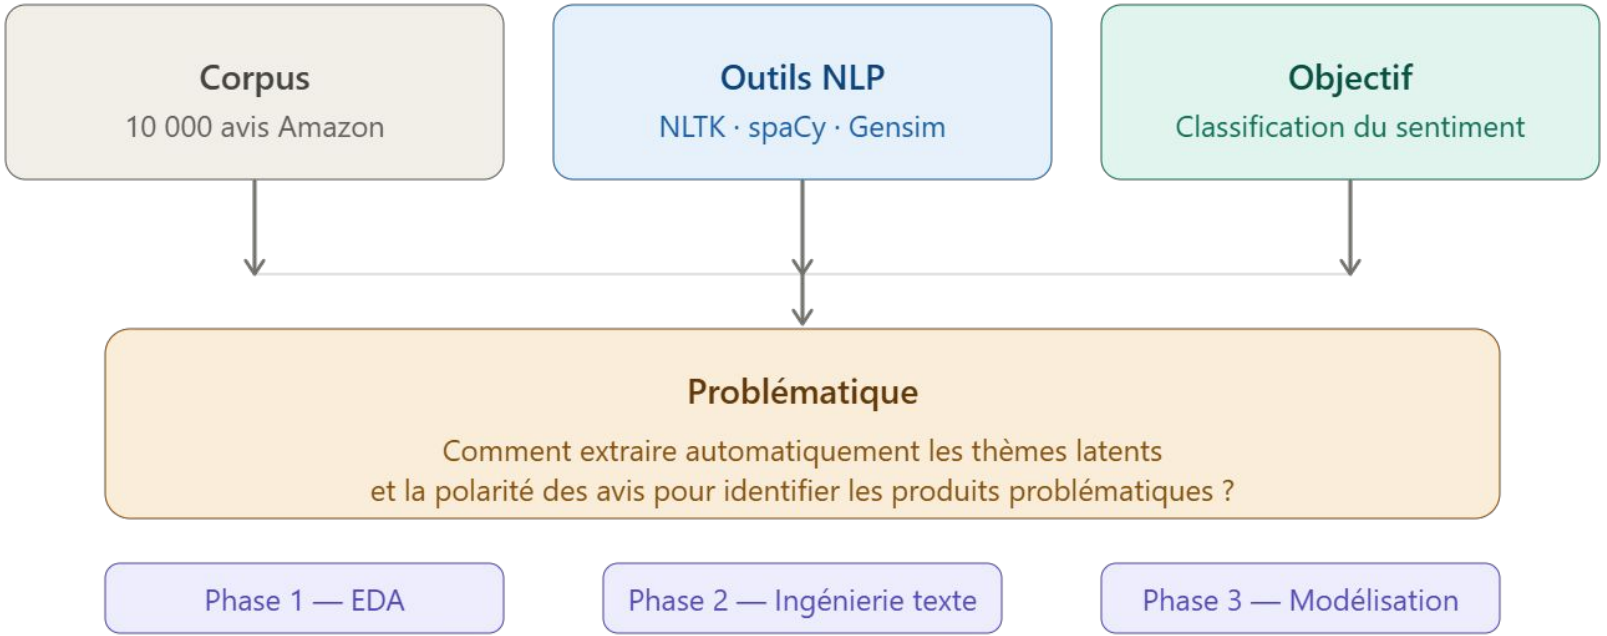
05 Analyse Temporelle & Produits

06 Conclusion & Perspectives

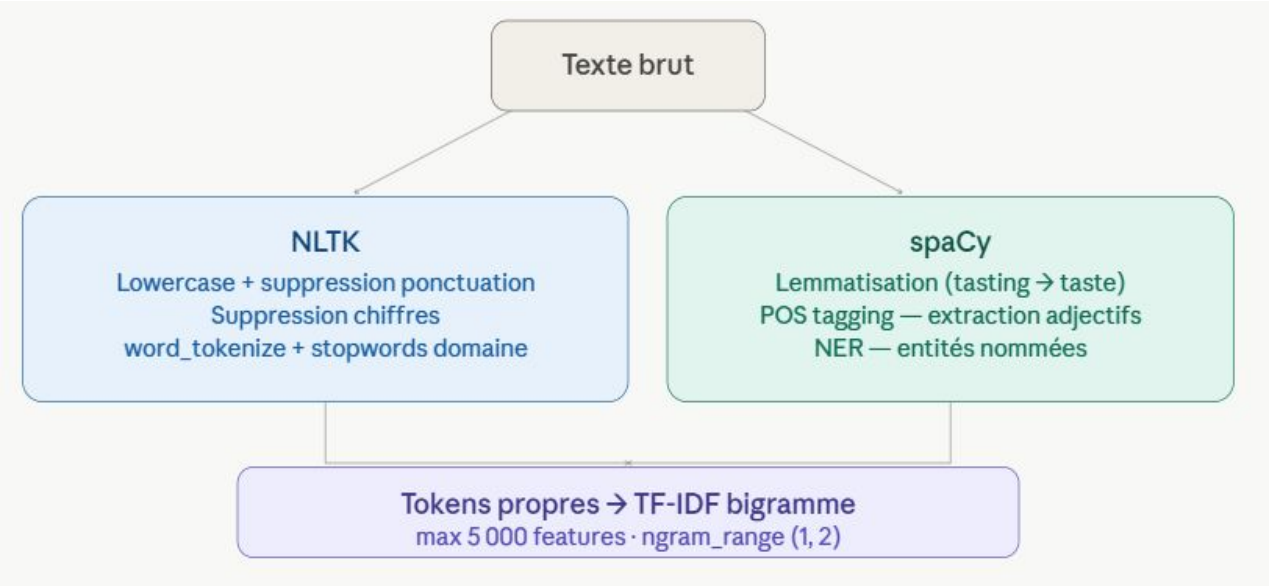
Problématique & Pipeline

Comment extraire automatiquement thèmes et polarité des avis clients ?

10 000 avis · 3 outils · 1 pipeline · 0 intervention humaine



Ingénierie du Texte



- NLTK nettoie
- spaCy lemmatise
- les adjectifs révèlent la polarité

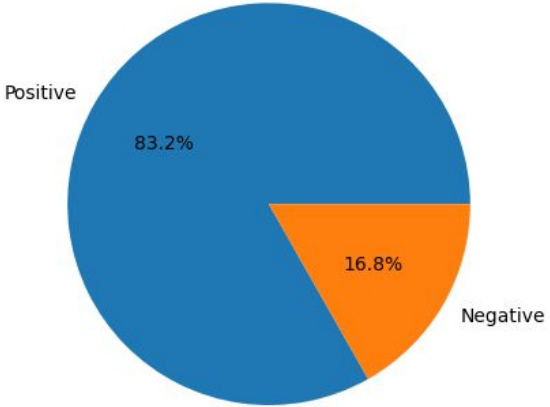
TF-IDF =texte -> vecteurs numériques en valorisant les mots les plus informatifs du corpus.

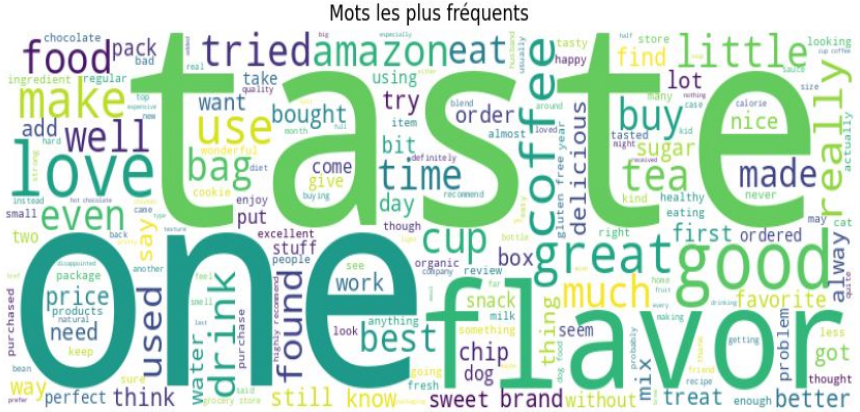
spaCy : bought → buy · tasting → taste · bad, dry, stale (avis négatifs)
NLTK : stopwords étendus → product, would, get supprimés du bruit

Analyse Exploratoire (EDA)

Structure du dataset

10 000	11 colonnes	2000 – 2012	Kaggle · MIT
avis conservés	dont 7 utiles	période couverte	source et licence

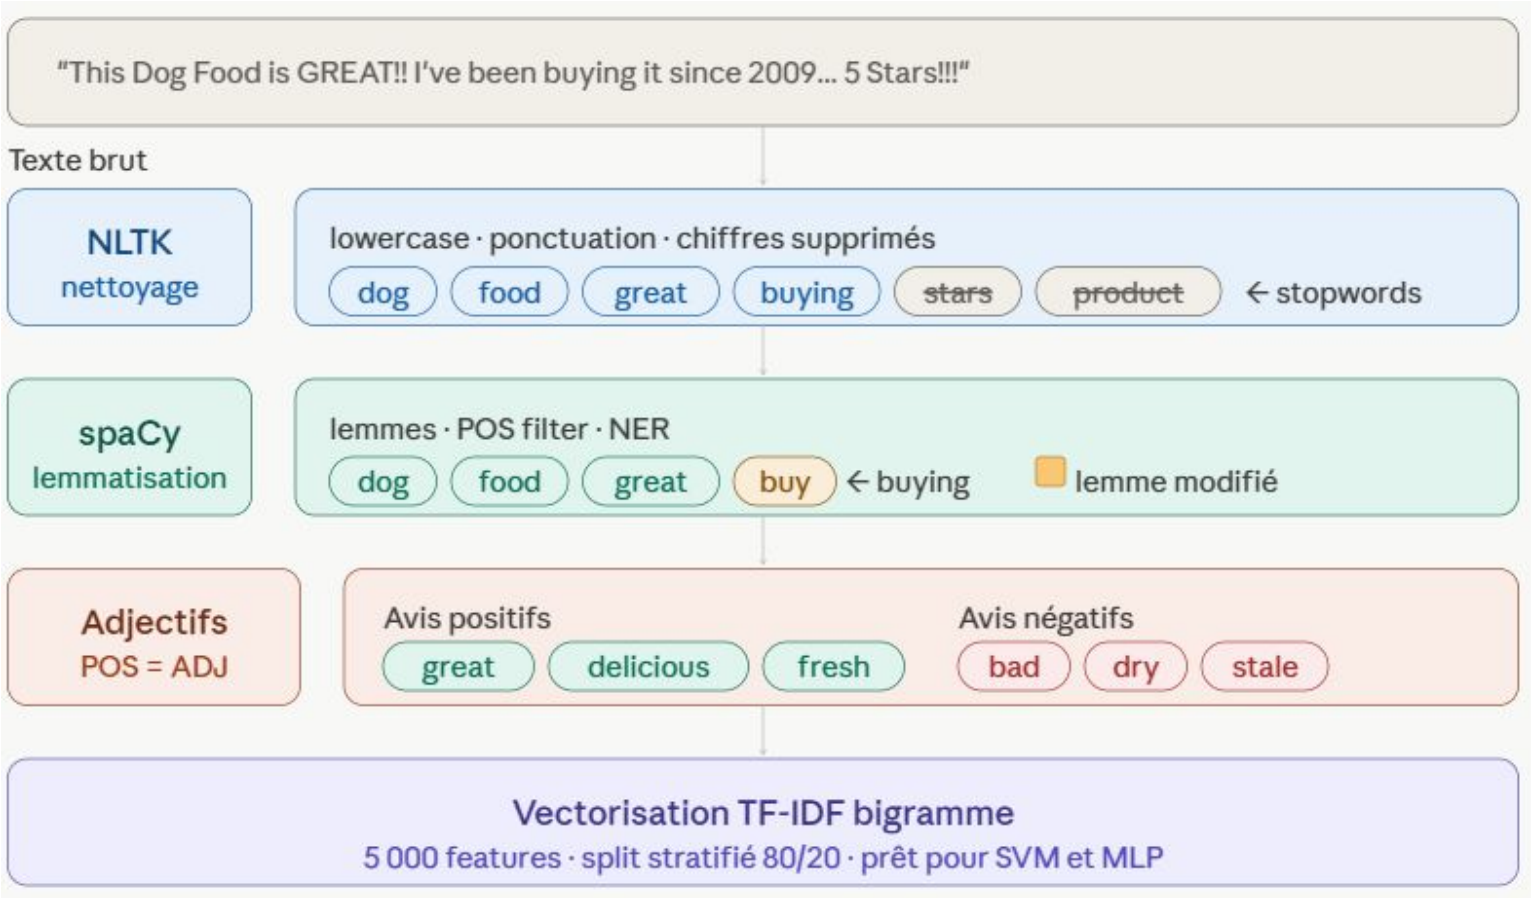




83% positifs — 17% négatifs : déséquilibre traité en phase 3 via SMOTE + class_weight

Les termes dominants sont taste,flavor,good = typiques d'un corpus alimentaire ou de commerce en ligne.

Modélisation Avancée



Modélisation Avancée

GENSIM

LDA — 4 thèmes latents

Thème 0 · Alimentation animaux
Thème 1 · Goût et satisfaction
Thème 2 · Café / thé
Thème 3 · Expérience achat Amazon

Word2Vec — d=100 · w=5

food → dog food · cat food · dry food
coffee → cup · brew · flavor · tea
useful → helpful · informative
Relations sémantiques capturées



4 thèmes découverts cohérents sans label

proximités sémantiques : coffee est proche de cup et brew.

Modélisation Avancée

```
=== SVM ===
              precision    recall  f1-score   support

    Negative       0.64      0.68      0.66       336
    Positive       0.93      0.92      0.93      1664

    accuracy                           0.88      2000
   macro avg       0.79      0.80      0.79      2000
weighted avg       0.88      0.88      0.88      2000
```

class_weight='balanced'
poids auto classe minoritaire

```
Avant SMOTE: 7998
Après SMOTE: 13310

=== MLP AVEC SMOTE ===
              precision    recall  f1-score   support

    Negative       0.71      0.59      0.64       336
    Positive       0.92      0.95      0.94      1664

    accuracy                           0.89      2000
   macro avg       0.81      0.77      0.79      2000
weighted avg       0.88      0.89      0.89      2000
```

SMOTE
7 998 → 13 310 exemples

SVM → meilleur rappel classe negative

MLP → meilleure précision classe negative

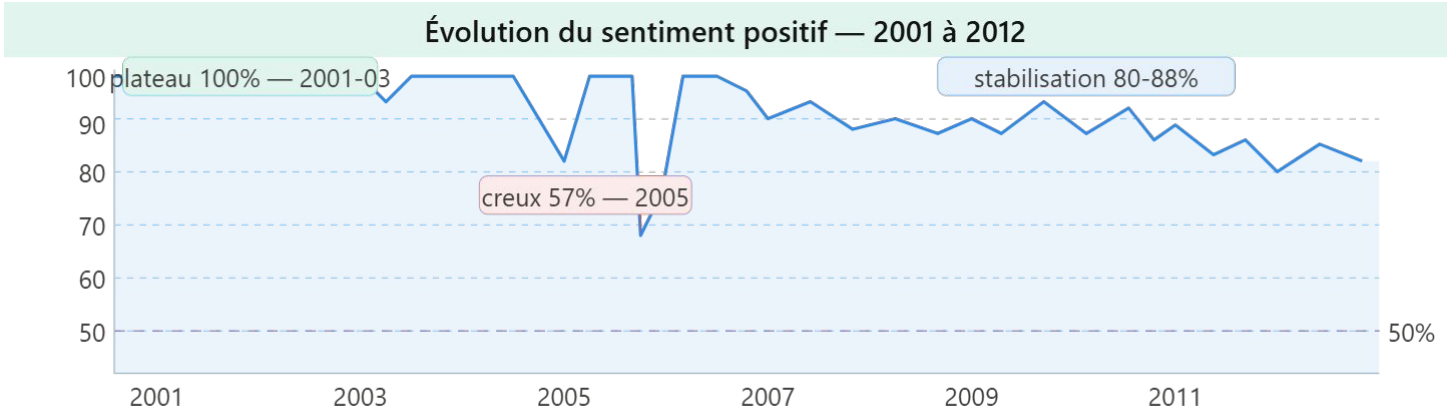
SVM détecte mieux les négatifs

Rappel = TP / (TP + FN) Est-ce que le modèle retrouve bien tous les vrais éléments d'une classe ?

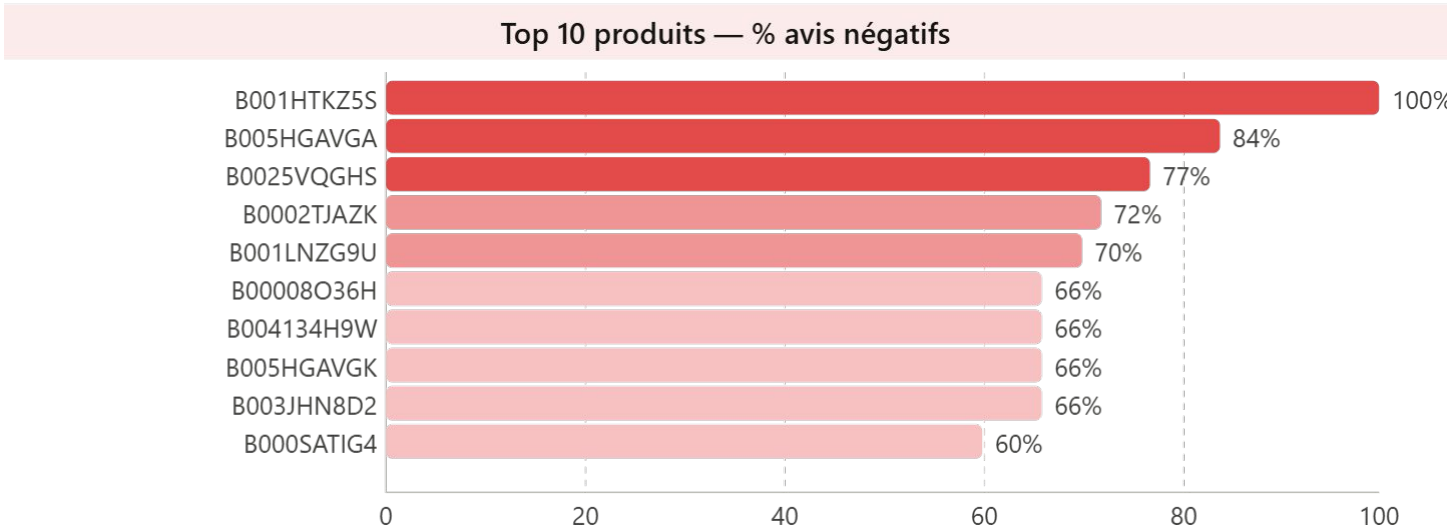
MLP les classe avec plus de précision

Précision = TP / (TP + FP)
Quand le modèle prédit une classe, est-ce qu'il a souvent raison ?

Analyse Temporelle & Produits



·Pic 2001–2003
· creux 2005
· stabilisation 80–88%



· B001HTKZ5S : 100% négatifs

Conclusion & Perspectives

CONTRIBUTIONS CLÉS

Contribution	Résultat
✅ Pipeline NLP complet NLTK · spaCy · Gensim · SVM · MLP	Du texte brut à la classification en 3 phases
✅ Gestion du déséquilibre 83/17 class_weight + SMOTE · 7998 → 13310	Détection des avis négatifs améliorée
✅ Performance solide SVM rappel 0.68 · MLP précision 0.71	Macro F1 = 0.79 · Accuracy = 89%
✅ Exploration non supervisée LDA · Gensim · aucun label requis	4 thèmes latents · coffee 0.042

PERSPECTIVES

Piste	Objectif
Fine-tuning BERT	Améliorer le rappel sur les avis négatifs
Démo Streamlit	Prédiction de polarité en temps réel



Merci pour votre attention

CREDITS: Diese Präsentationsvorlage wurde von **Slidesgo** erstellt, inklusive Icons von **Flaticon** und Infografiken & Bilder von **Freepik**