DÉTECTION AUTOMATIQUE DES DISCOURS HAINEUX EN DIALECTE TUNISIEN



Présenté par : Salma Mlika
Encadré par : M. Mehdi Selem

Année universitaire 2025 - 2026

PLAN

01 INTRODUCTION

02 PRÉPARATION DES DONNÉES

03 MODÉLISATION

04 CONCLUSION

INTRODUCTION

CONTEXTE ET OBJECTIF

🔍 PROBLÉMATIQUE

Les réseaux sociaux tunisiens font face à une augmentation du contenu toxique en dialecte tunisien.

⚠️ DÉFIS

- Dialecte non-standard (mélange arabe/français/arabizi)

- Manque d'outils de modération adaptés

- Impact négatif sur les utilisateurs

🎯 **OBJECTIF** détecter automatiquement les contenus toxiques en dialecte tunisien

📊 DONNÉES



0	قطع يد السارق توفرت الشروط شرط الحد الأدنى قيم...	normal
1	تلوموش لطفي لعبدلي شرف	normal
2	مستغرب شعب يسمع تفاهة شانو لى الدرجة الشعب تاف...	normal
3	هههخ غزلتني مافهمتش شمدخلها الموضوع تتنظر وحده...	normal
4	ترضى اليهود والنصارى تتبع ملتهم الحمد لله يوجد...	hate

PIPELINE METHODOLOGIQUE



INTRODUCTION

TECHNOLOGIES ET CONCEPTS CLÉS

Qu'est-ce que BERT ?

BERT = Bidirectional Encoder Representations from Transformers

Concept simplifié:

- 🧠 **Un modèle qui "lit" le texte dans les deux sens**

Phrase: "Le chat mange la souris"

BERT comprend "chat" en regardant "Le" ET "mange" simultanément

- 📚 **Pré-entraîné sur des milliards de mots**

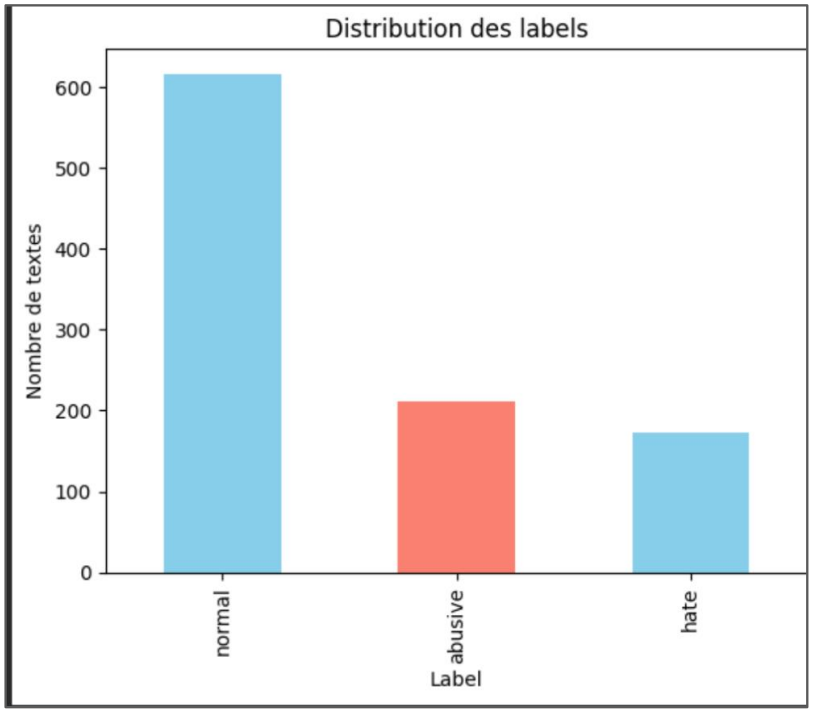
Connaît déjà la grammaire et le vocabulaire

AraBERT = Version optimisée pour l'arabe



ÉQUILIBRAGE DES CLASSES

PROBLÈME ⚠️




```
Distribution Initiale - LE PROBLÈME ⚠️

Normal (616)    ████████████████  61.8%
Abusive (212)   ██████            21.3%
Hate (172)      ████              17.2%
```

❌ Déséquilibre majeur → Modèle biaisé

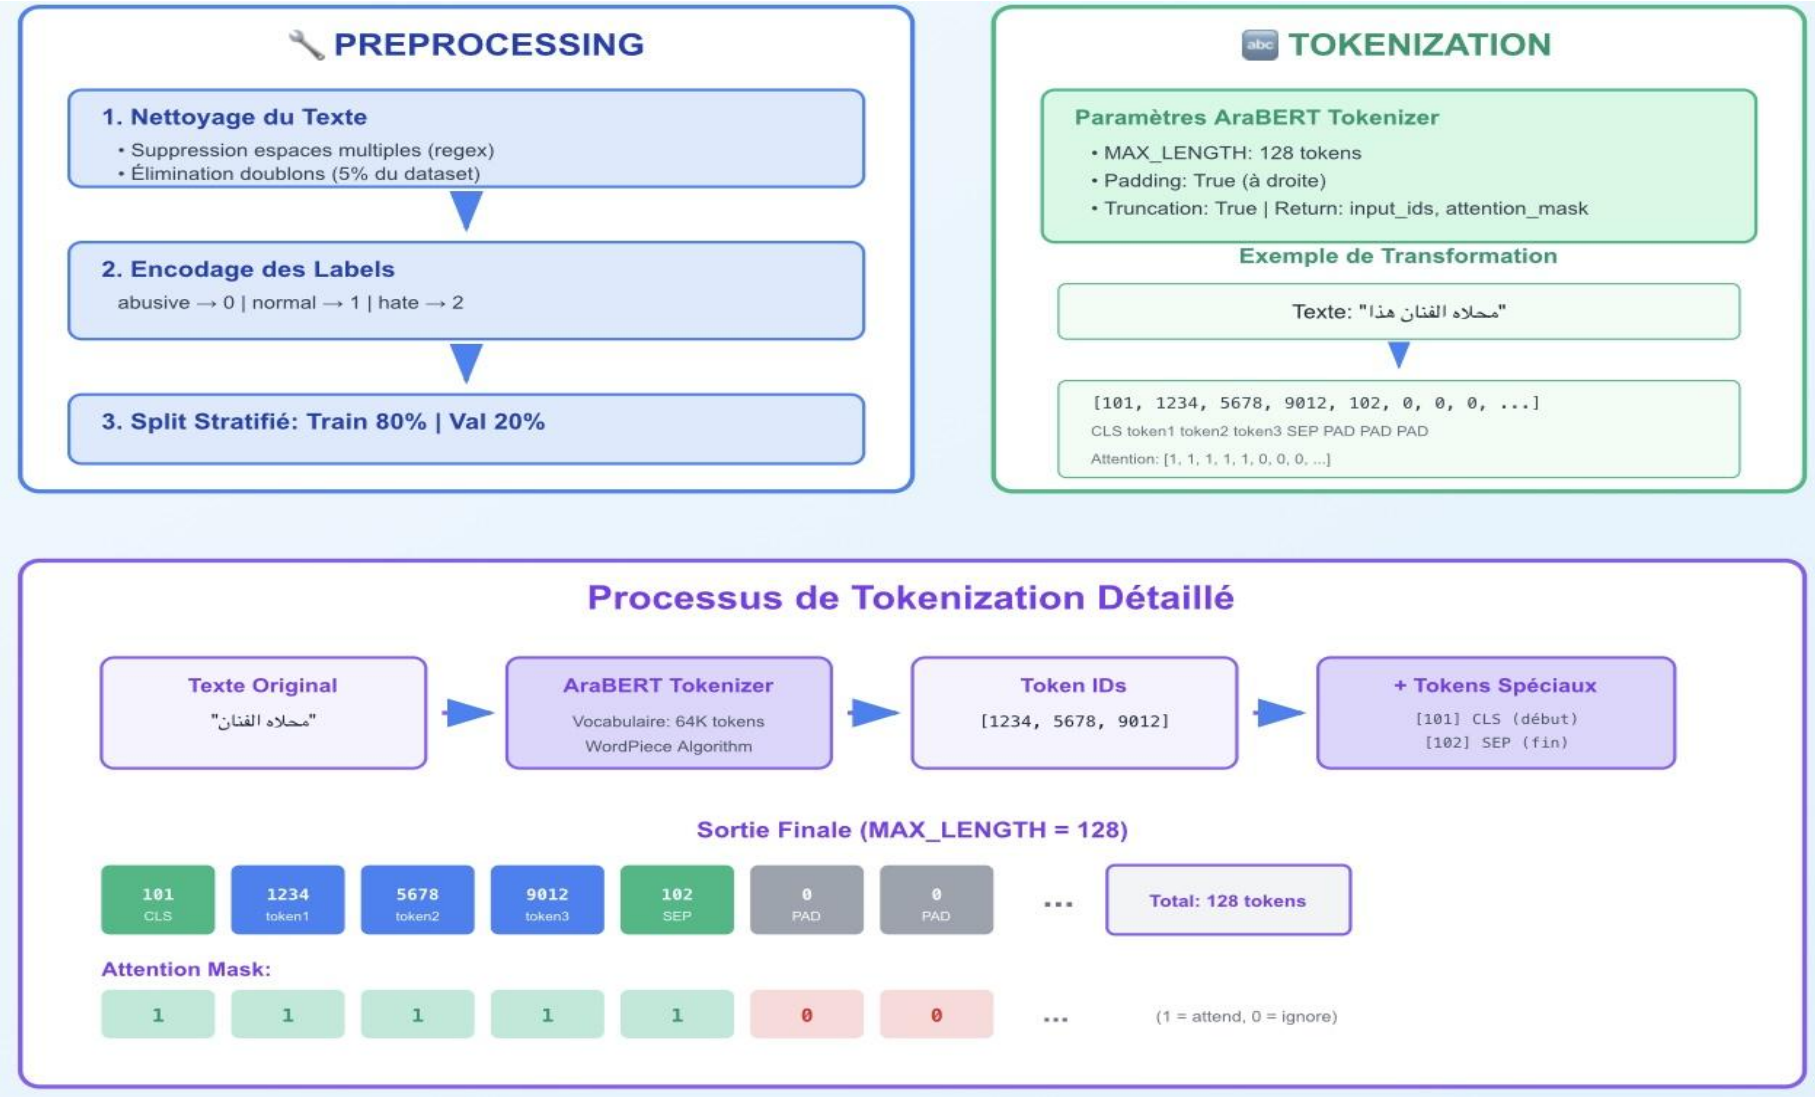
✅ Dataset équilibré → Modèle performant

```
Après Downsampling - LA SOLUTION ✅

Normal    ████  30.9%  (172)
Abusive   ████  38.1%  (212)
Hate      ████  30.9%  (172)
```

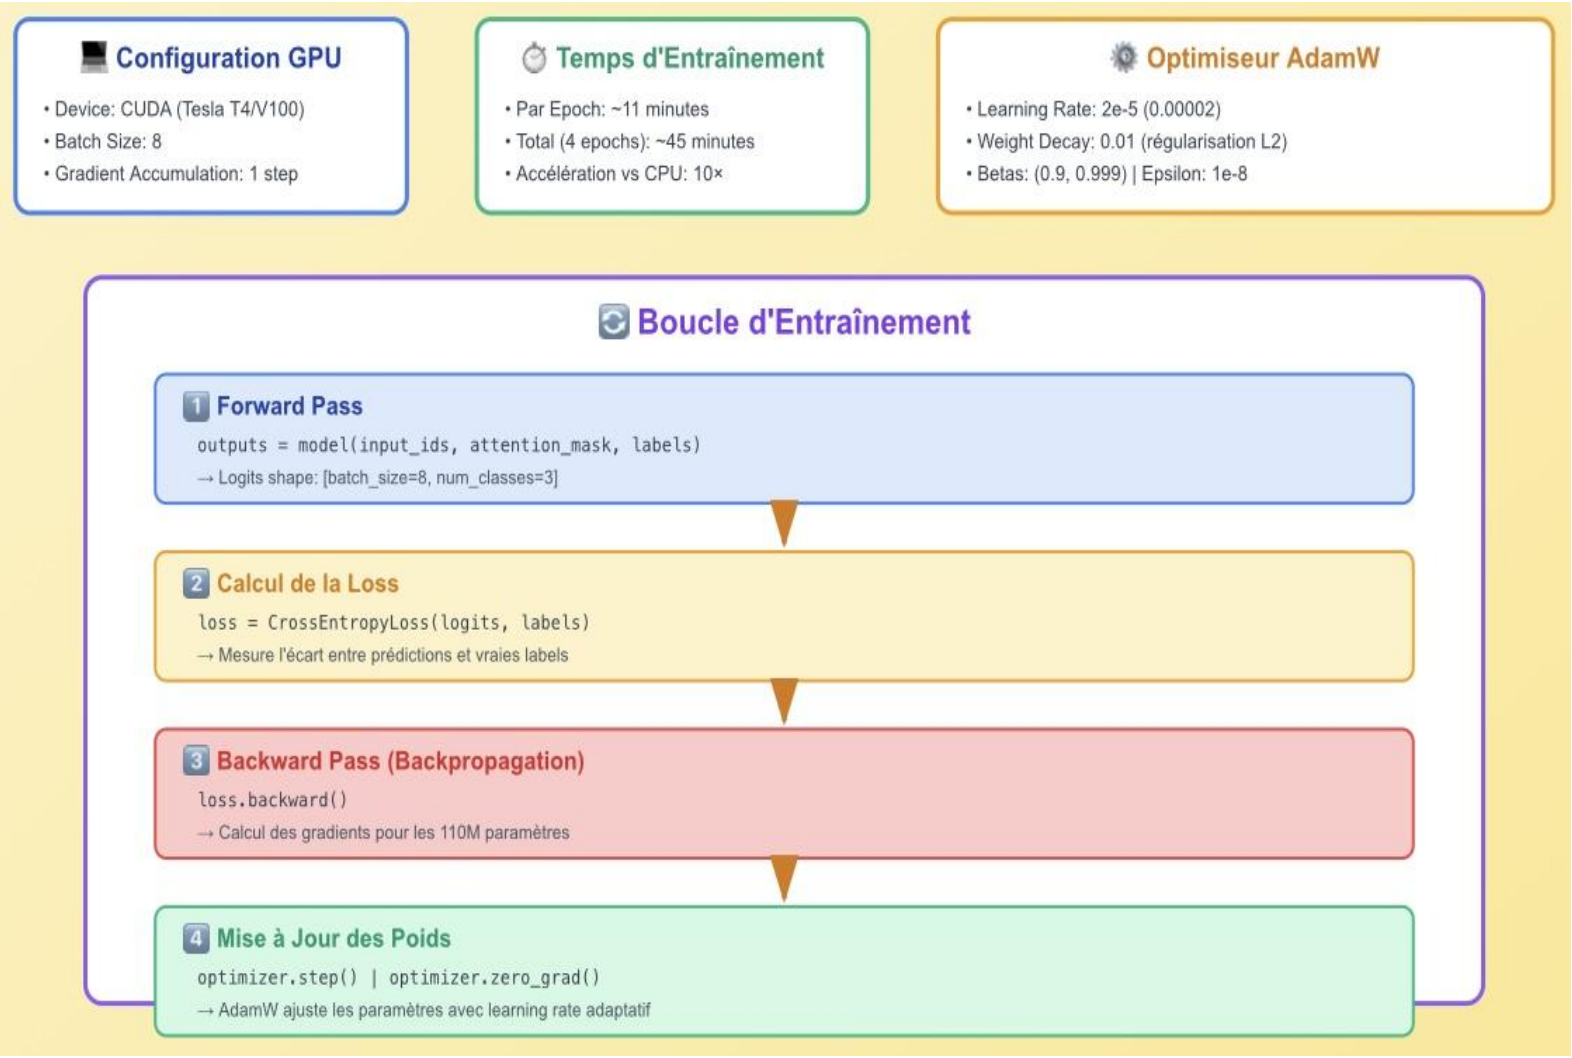
PRÉPARATION DES DONNÉES

PREPROCESSING ET TOKENIZATION



MODÉLISATION

PROCESSUS D'ENTRAÎNEMENT



- **FORWARD PASS**

Le modèle lit le texte et produit des scores (logits).

- **LOSS**

Mesure l'erreur entre la prédiction et la vraie classe.

- **BACKWARD PASS**

Calcule comment corriger les paramètres du modèle.

- **UPDATE**

Met à jour les poids pour améliorer le modèle.

MODÉLISATION

RÉSULTATS COMPARATIFS

🏆 PERFORMANCE FINALE (Recall)

🟠 ABUSIVE	0.81	⭐⭐⭐
🔴 HATE	0.41	⭐⭐
🟢 NORMAL	0.37	⭐

Accuracy Globale: 55%

F1 Pondéré: 0.54

AVANT (Biaisé)

68%

Score élevé mais "triche"

Il prédit 'Normal' par défaut

APRÈS (Équilibré)

55%

Plus honnête & utile

Détecte mieux les insultes

💡 INSIGHT CLÉ

Le downsampling sacrifie volontiers la performance sur "Normal" pour améliorer drastiquement la détection des contenus TOXIQUES.

✅ Trade-off ACCEPTABLE pour la modération de contenu !

MODÉLISATION

DÉMONSTRATION PRATIQUE

🔴 EXEMPLE 1 : Discours Haineux

Texte: "ترضى اليهود والنصارى تتبع ملتهم"

"...الحمد لله يوجد"

🤖 Prédiction: HATE 🔥

✅ CORRECT !

🟢 EXEMPLE 3 : Texte Normal

Texte: "محلاه الفنان هذا، متربي برشا"

🤖 Prédiction: NORMAL 😊

✅ CORRECT !

🟠 EXEMPLE 2 : Contenu Abusif

Texte: "انت بهيم و تافه وما تفهم حتى حاجة"

🤖 Prédiction: ABUSIVE 😠

✅ CORRECT !

💡 **Le modèle comprend les NUANCES du dialecte tunisien et le CONTEXTE !**

CONCLUSION

CONCLUSION

✅ RÉALISATIONS

- ✓ Système fonctionnel pour le tunisien
- ✓ Amélioration +45% sur contenus abusifs
- ✓ Dataset équilibré et reproductible
- ✓ Pipeline modulaire et extensible

🔮 PERSPECTIVES D'AMÉLIORATION

1. 1️⃣ Augmentation de données (SMOTE)
2. 2️⃣ Extension à d'autres dialectes arabe
3. 3️⃣ Intégration multimodale (texte + images)
4. 4️⃣ Déploiement via API REST



L'IA au service d'un internet plus sain et respectueux pour la communauté tunisienne 🇹🇳



Merci pour votre attention

CREDITS: Diese Präsentationsvorlage wurde von **Slidesgo** erstellt, inklusive Icons von **Flaticon** und Infografiken & Bilder von **Freepik**