PRÉDICTION DU STOCK D'EAU DANS LES BARRAGES TUNISIENS



Présenté par : Salma Mlika

Année universitaire 2025 - 2026

PLAN

01 INTRODUCTION

02 PRÉPARATION DES DONNÉES

03 MODÉLISATION

04 CONCLUSION

INTRODUCTION

CONTEXTE ET OBJECTIF

📌 CONTEXTE TUNISIEN

- Stress hydrique : 420 m³/hab/an (seuil ONU : 500 m³)
- Enjeu : Optimiser irrigation, eau potable..

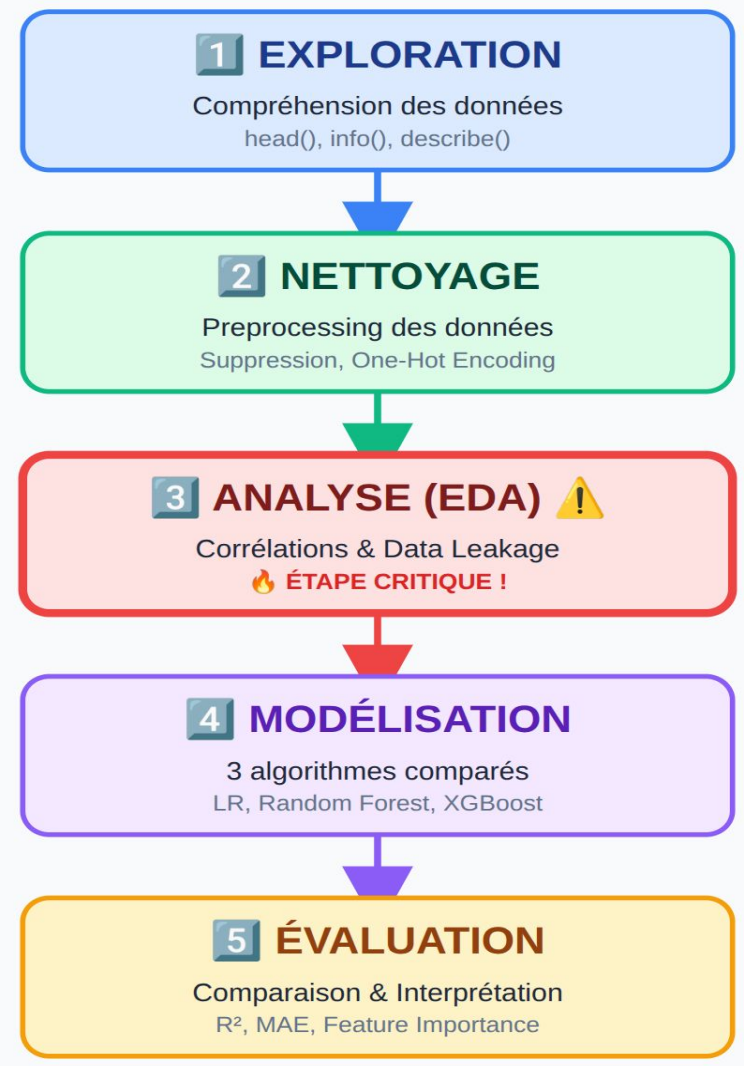
🎯 **OBJECTIF** Prédire le stock quotidien ou hebdomadaire des barrages

📊 DONNÉES OFFICIELLES

- 🏛️ Source :**data.gov.tn** (Open Data Tunisie)
- 36 barrages tunisiens
- ~3132 observations (2025)
- Mesures journalières validées

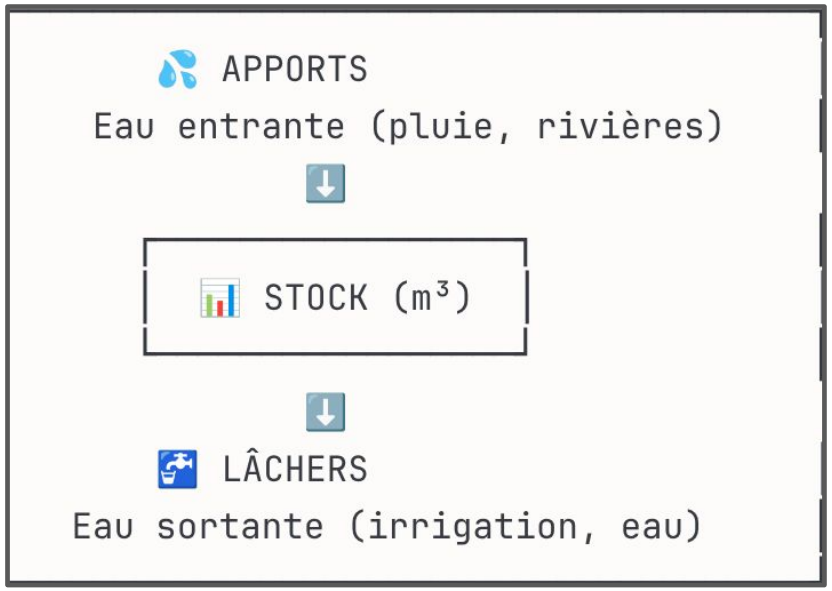
_id	Date	Nom_Fr	Nom_Ar	Latitude	Longitude	Bassin_versant
1	2025-10-12T00:00:00	سدّ الملاّق	Barrage MELLEGUE	36.3144	8.70273	10300.0
2	2025-10-12T00:00:00	سدّ سارّات	Barrage SARRAT	49.9167	26.58330	1850.0
3	2025-10-12T00:00:00	سدّ بني مطير	Barrage BEN METIR	36.7471	8.74188	103.0

PIPELINE METHODOLOGIQUE



FEATURES ET CONCEPTS CLÉS

💧 CONCEPTS CLÉS



ÉQUATION DU STOCK

Stock(t) = Stock(t-1) + Apports - Lâchers

🔧 DESCRIPTION DES FEATURES (25)

🏷️ IDENTIFIANTS (5)
id_barrage, Date, Nom_Fr, Nom_Ar, _id
→ Identification unique des observations

📍 GÉOSPATIALES (3)
Latitude, Longitude, Bassin_versant
→ Position et surface du bassin versant

🏗️ CARACTÉRISTIQUES PHYSIQUES (3)
Cap_tot_init, Cap_tot_act, Cote
→ Capacités du barrage et niveau d'eau

💦 FLUX HYDROLOGIQUES (6)
apports, lachers, cumul_mensuel/annuel
→ Entrées et sorties d'eau + cumuls

📊 DONNÉES HISTORIQUES (4)
moy_mois, moy_periode, stock/cumul_préc
→ Moyennes et valeurs année précédente

🎯 VARIABLE CIBLE (1)
stock : Volume d'eau stocké (m³)
→ Ce que nous voulons prédire

NETTOYAGE DES DONNÉES

✅ QUALITÉ DES DONNÉES

✓ Aucune valeur manquante

✓ Aucun doublon

🗑️ SUPPRESSIONS

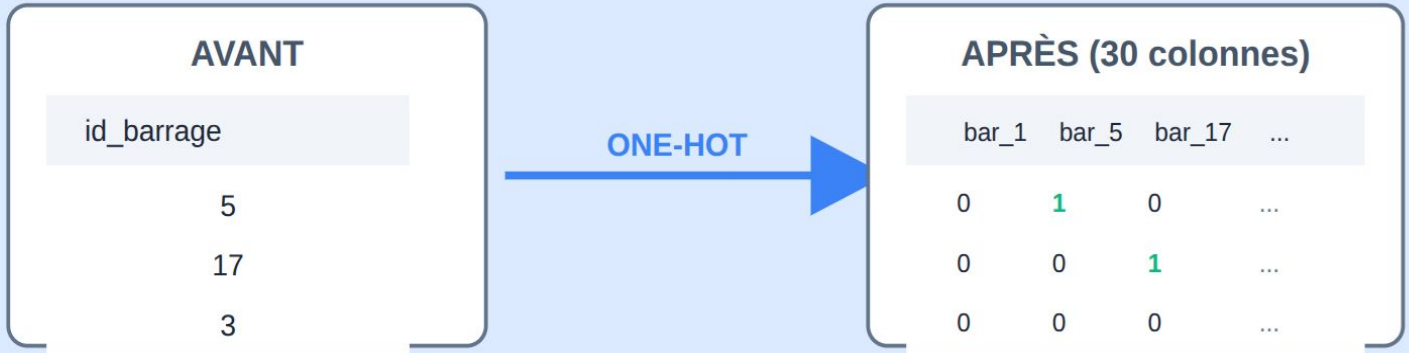
❌ **Nom_Fr, Nom_Ar** → Identifiants redondants

❌ **fonctionnel** → Constante (toujours = 1)

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 3132 entries, 0 to 3131
Data columns (total 23 columns):
 #   Column                  Non-Null Count  Dtype
---  ------                  --------------  -----
 0   _id                     3132 non-null   int64
 1   Date                    3132 non-null   object
 2   Nom_Fr                  3132 non-null   object
 3   Nom_Ar                  3132 non-null   object
 4   Latitude                3132 non-null   float64
 5   Longitude               3132 non-null   float64
 6   Bassin_versant          3132 non-null   float64
 7   fonctionnel             3132 non-null   int64
 8   apports                 3132 non-null   float64
 9   id_barrage              3132 non-null   int64
 10  lachers                 3132 non-null   float64
 11  stock                   3132 non-null   float64
 12  cumul_mensuel_apports   3132 non-null   float64
 13  cumul_annuel_apports    3132 non-null   float64
 14  cumul_mensuel_lachers   3132 non-null   float64
 15  cumul_annuel_lachers    3132 non-null   float64
 16  moy_mois                3132 non-null   float64
 17  cumul_annee_prec        3132 non-null   float64
 18  moy_periode             3132 non-null   float64
 19  stock_annee_prec        3132 non-null   float64
 20  Cap_tot_act             3132 non-null   float64
 21  Cote                    3132 non-null   float64
 22  Cap_tot_init            3132 non-null   float64
dtypes: float64(17), int64(3), object(3)
memory usage: 562.9+ KB
```

FEATURE ENGINEERING

1️⃣ ID BARRAGE → One-Hot Encoding



2️⃣ DATE → MOIS (1-12)



💡 POURQUOI ?

Chaque barrage a un comportement UNIQUE (climat, taille, usage)

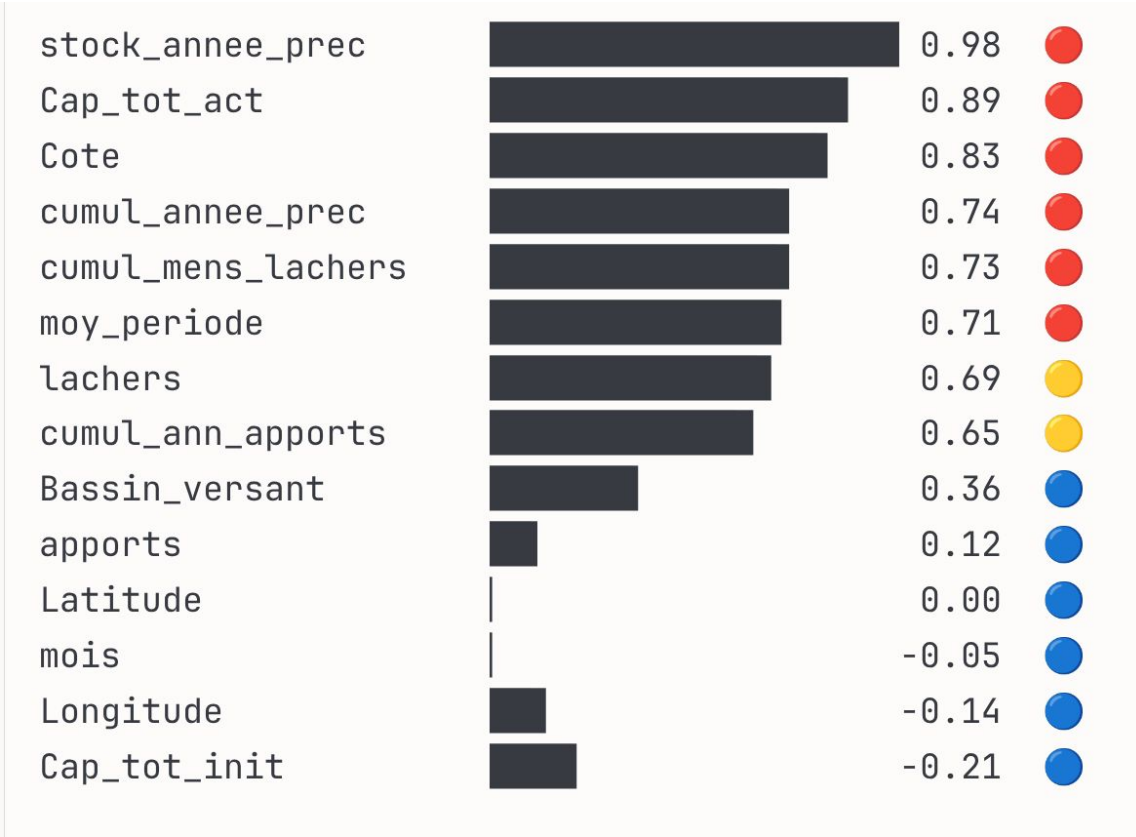
Ex: Barrage de Sidi Salem (17) ≠ Petit barrage du sud (3)

Le modèle peut apprendre ces différences spécifiques

💡 Capture la SAISONNALITÉ : Hiver = pluies, Été = sécheresse

PRÉPARATION DES DONNÉES

ANALYSE DE CORRÉLATION



🔴 > 0.7 = DATA LEAKAGE !
🟡 0.5-0.7 = À surveiller
🔵 < 0.5 = Normal

📅 Mois

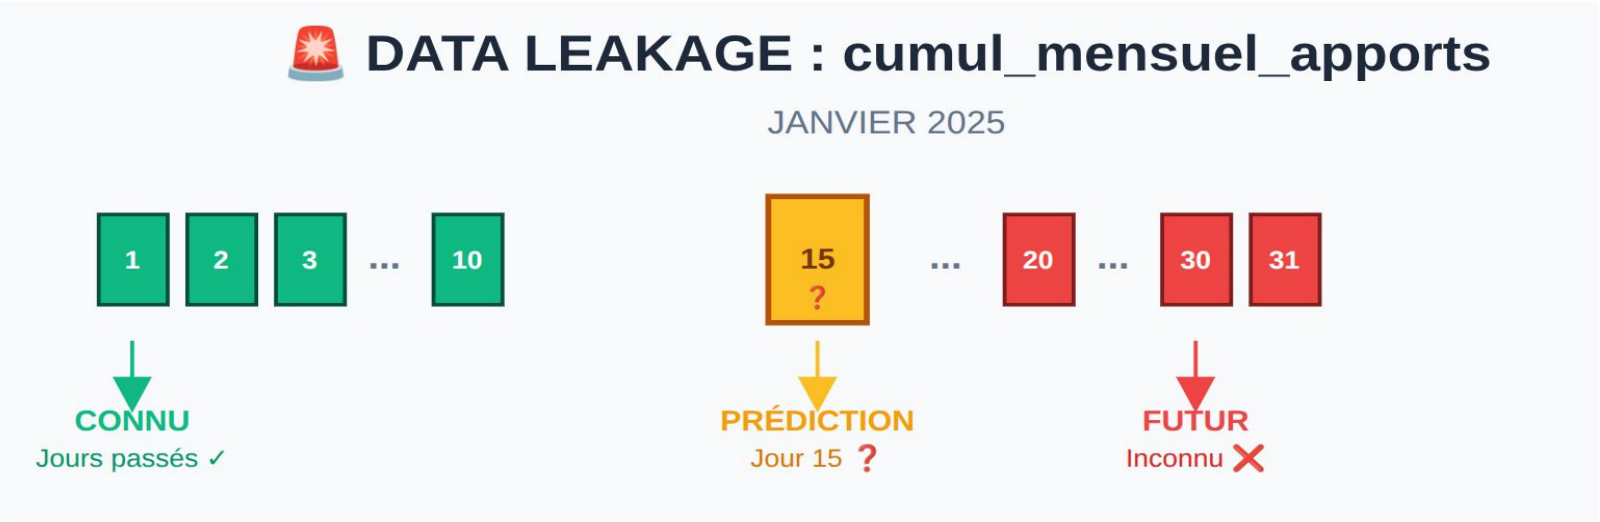
- Stock non-linéaire selon le mois : haut en début/fin d'année, bas au milieu.
- Corrélation linéaire proche de zéro (relation non-linéaire).
- **Décision : ON GARDE** pour capturer la saisonnalité.

🌍 Latitude / Longitude

- Corrélation linéaire faible, mais ces variables captent la localisation (climat).
- Random Forest peut gérer les relations non-linéaires.
- **Décision : ON GARDE**

⚠️ **Variables fortement corrélées (>0,7)** :
À investiguer → Slide suivant

DATA LEAKAGE - LE PROBLÈME ⚠️



Définition simple :
utiliser des informations qui ne seraient pas disponibles au moment de la prédiction réelle.

⚠️ LE PROBLÈME

cumul_mensuel_apports = Somme(apports jour 1 → jour 31)

Cette variable INCLUT les jours 16–31 = DONNÉES DU FUTUR !

🚨 C'EST DE LA TRICHE

Le modèle « voit » l'avenir →
Performance artificielle →
Inutilisable en production

DATA LEAKAGE - LA SOLUTION ✅

❌ 9 variables supprimées :

Variable	Corrélation	Raison
❌ stock_annee_prec	0.98	Dépend du stock
❌ Cap_tot_act	0.89	Calculée après
❌ Cote	0.83	Proxy du stock
❌ cumul_annee_prec	0.74	Inclut le futur
❌ cumul_mens_lachers	0.73	Inclut le futur
❌ moy_periode	0.71	Moyenne globale
❌ cumul_ann_apports	0.65	Inclut le futur
❌ cumul_ann_lachers	0.64	Inclut le futur

✅ VARIABLES GARDÉES (disponibles en temps réel)

✓ apports (jour)	0.12	Mesure du jour
✓ lachers (jour)	0.69	Mesure du jour
✓ Latitude	0.00	Fixe
✓ Longitude	-0.14	Fixe
✓ Bassin_versant	0.36	Fixe
✓ Cap_tot_init	-0.21	Fixe
✓ mois	-0.05	Connu

MODÉLISATION - 3 ALGORITHMES

RÉGRESSION LINÉAIRE

Baseline simple

$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \ldots$

RANDOM FOREST

200 arbres en parallèle

Moyenne des prédictions

XGBOOST 🏆

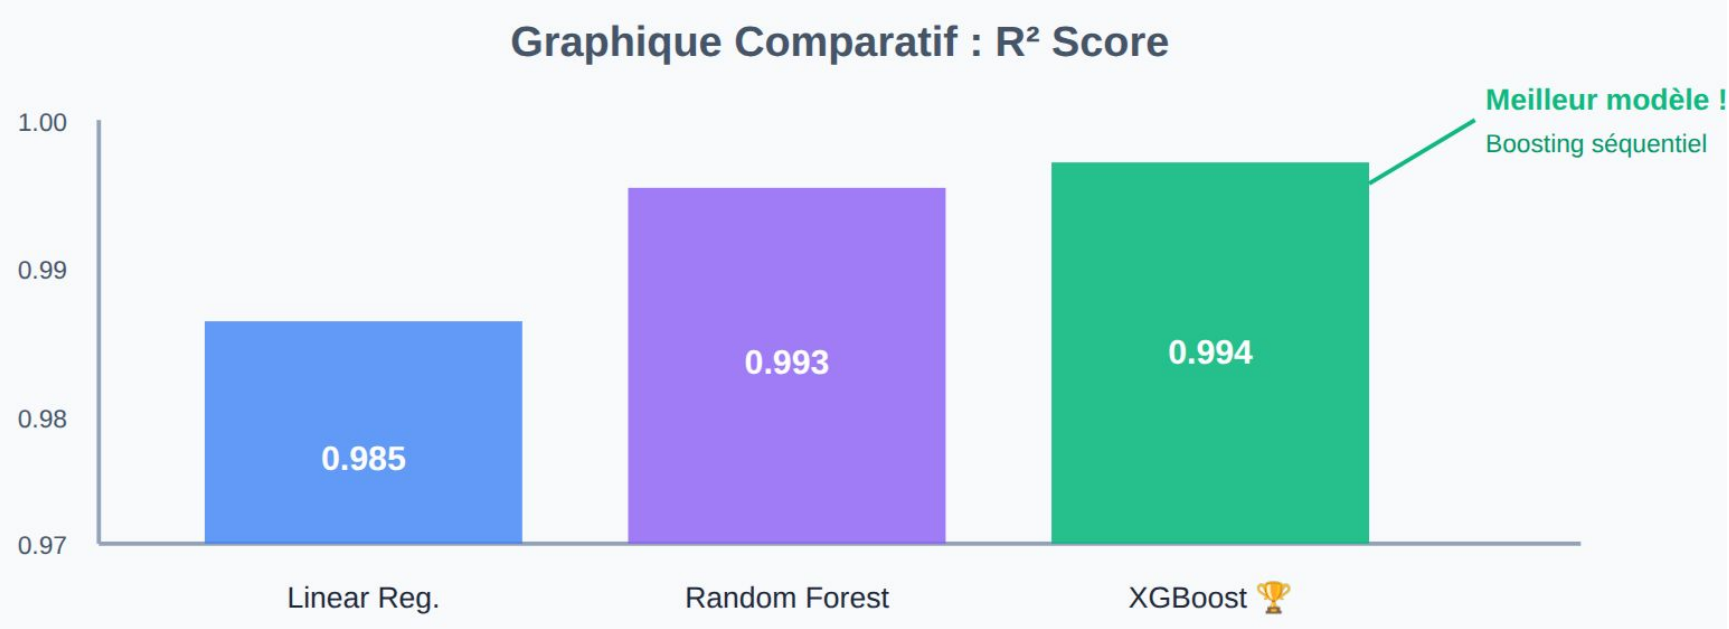
200 arbres séquentiels

Chaque arbre corrige le précédent

✅ **De plus simple , au plus performant**

MODÉLISATION

RÉSULTATS COMPARATIFS



📝**Boosting séquentiel = apprentissage étape par étape où chaque modèle améliore les erreurs du précédent.**

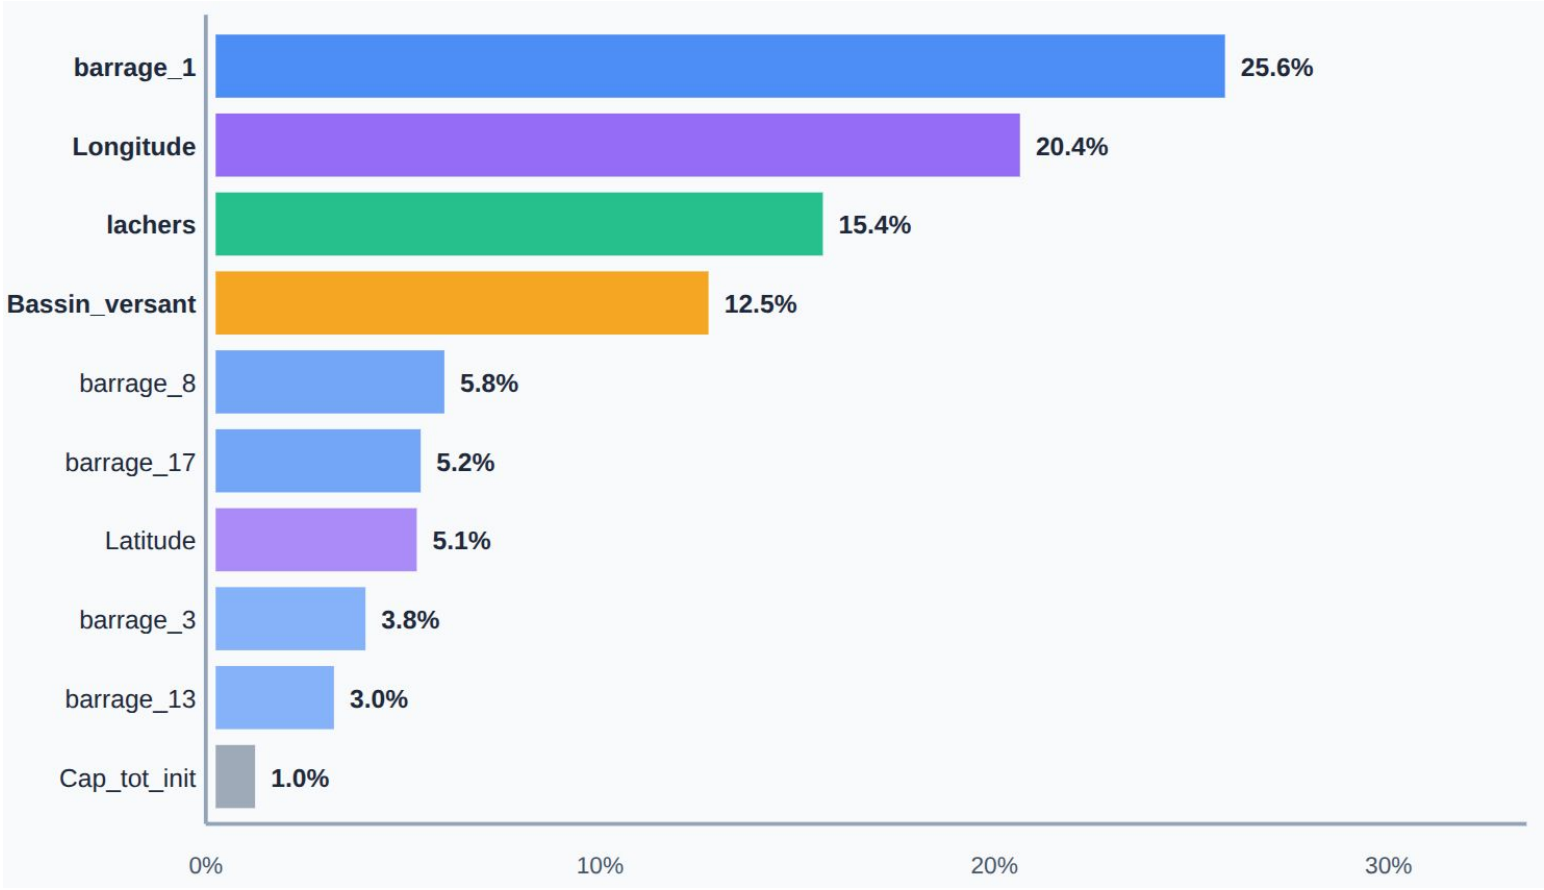
Modèle	R^2	MAE
Linear Regression	0.985	1.96
Random Forest	0.993	0.60
XGBoost 🏆	0.994	0.53

R^2 = Proportion de variance expliquée (max = 1.0)
MAE = Erreur moyenne

MODÉLISATION

FEATURE IMPORTANCE

TOP 10 FEATURES LES PLUS IMPORTANTES (XGBoost)



INTERPRÉTATION :

🌍 Barrages spécifiques (1, 8, 17) = Comportements uniques

💧 lachers = Impact direct sur le stock

🌍 aspects Géographie (Long, Lat, Bassin) = Climat local

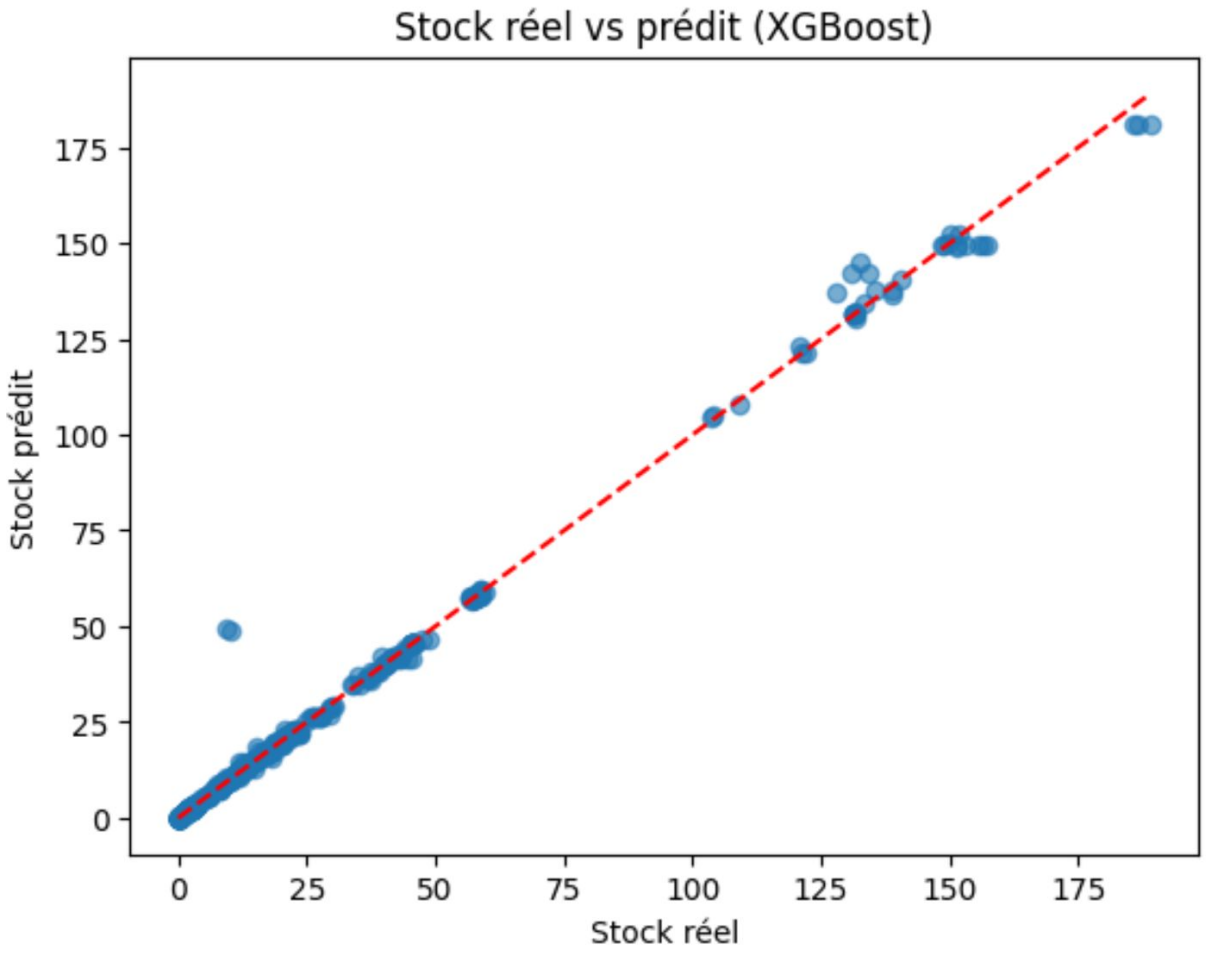
=>Le modèle bien **appris les patterns pertinents**.

(`Plus la colonne réduit l'erreur des arbres, plus XGBoost lui attribue une haute importance`

)

MODÉLISATION

Graphique Scatter : Réel vs Prédit



Points alignés sur diagonale = bon

CONCLUSION

🎯 CONTRIBUTIONS CLÉS

✅ Identification du data leakage
→ Rigueur méthodologique

✅ Modèle déployable en production
→ Pensée pratique, pas théorique

✅ Performance solide (R^2 = 0.994)
→ XGBoost optimal

✅ Interprétabilité
→ Feature importance claire

💧 UTILITÉ OPÉRATIONNELLE

- Prédictions en temps réel de la demande
- Optimisation de la distribution d'eau
- Détection rapide des anomalies/fuites

🚀 PISTES D'AMÉLIORATION

📊 ENRICHISSEMENT DES DONNÉES

→ Intégrer données météo (température)
→ Inclure données démographiques

🤖 OPTIMISATION DU MODÈLE

→ Hyperparameter tuning approfondi
→ Tester modèles séries temporelles (LSTM)
→ Feature engineering avancé



Merci pour votre attention

CREDITS: Diese Präsentationsvorlage wurde von **Slidesgo** erstellt, inklusive Icons von **Flaticon** und Infografiken & Bilder von **Freepik**